Modelo único vs. Ensemble na detecção de pneumonia

2ª Avaliação – Eletiva de Inteligência Artificial

Enzo de Barros Nunes Guilherme Cardozo de Castro Melo Lui Vaz Manso de Queiroz
Marcelo Bresani Victor de Oliveira Matheus de Lucena Henriques Thiago de Lima von Sohsten

CESAR School — Recife, PE

28 de outubro de 2026

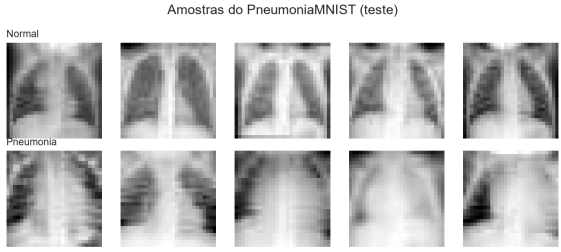
Problema e objetivo

- Classificar radiografias de tórax: normal vs. pneumonia.
- Três técnicas: **classificação**, **transfer learning**, **ensemble** (alternativa: modelo único).
- 30 simulações; inferir H0 ou H1 com teste estatístico ($\alpha = 0{,}05$).

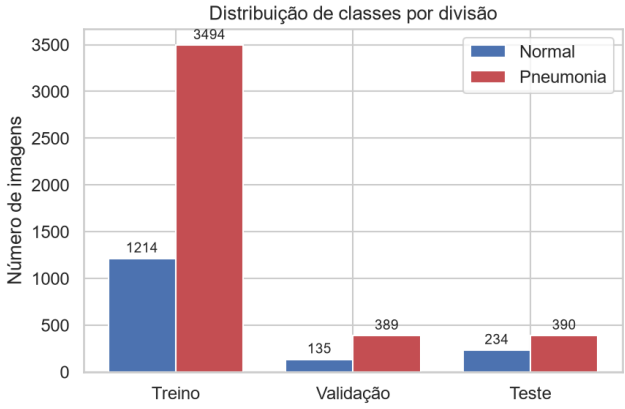
Dataset

PneumoniaMNIST (MedMNIST): 28×28 nativo, redimensionado para 64×64; divisão fixa treino/val/teste.

- Pré-processamento: 3 canais + normalização ImageNet.
- Métrica principal: **F1** (classes desbalanceadas).



Distribuição de classes

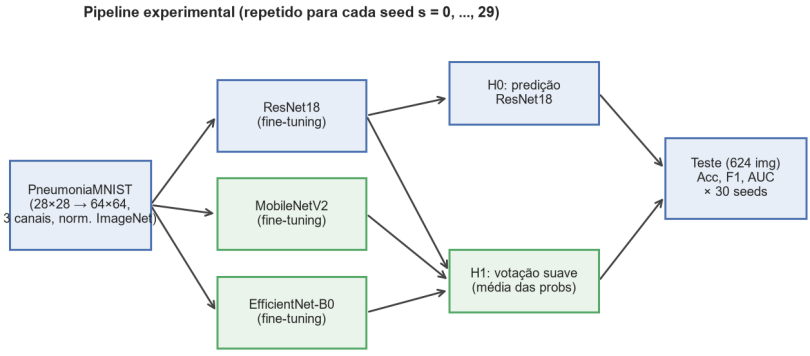


Cenários comparados

	Técnica C
H0 (hipótese nula)	ResNet18 único
H1 (hipótese alternativa)	Ensemble: ResNet18 + MobileNetV2 + EfficientNet-B0

Votação suave (média de probabilidades). Mesma ResNet18 treinada em ambos (pareamento).

Pipeline experimental



Protocolo experimental

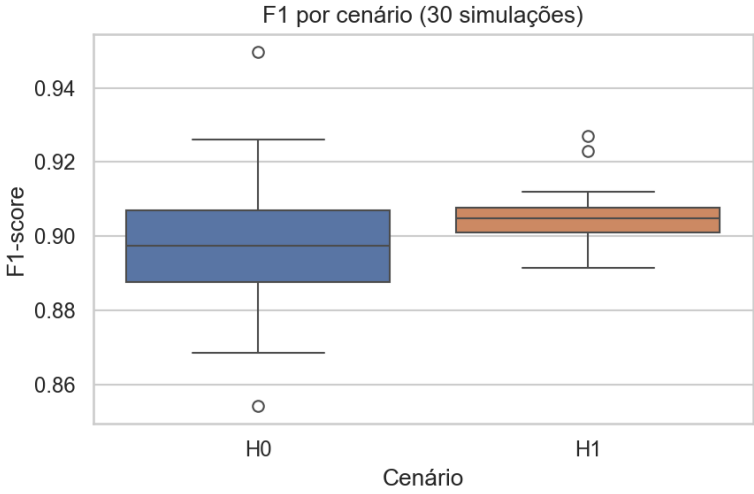
- Seeds 0–29; Adam, lr 10^{-3}, batch 128, até 5 épocas + early stopping.
- Shapiro-Wilk $\rightarrow$ t pareado ou Wilcoxon (unilateral: H1 $>$ H0).
- Cohen's d e gráficos em `results/figs/`.

Resultados numéricos (30 simulações)

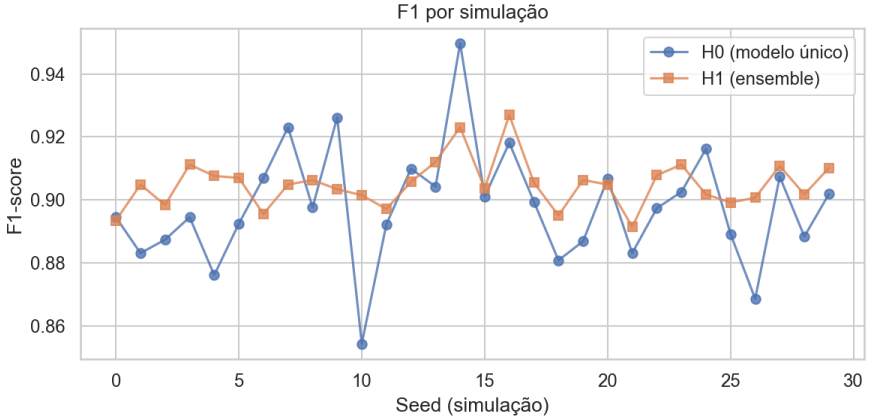
Cenário	Acurácia	F1	AUC
H0 (modelo único)	0,8580 $\pm$ 0,0286	0,8980 $\pm$ 0,0184	0,9691 $\pm$ 0,0093
H1 (ensemble)	0,8690 $\pm$ 0,0118	**0,9050 $\pm$ 0,0077**	0,9677 $\pm$ 0,0074

- H1 vence em **22 de 30** seeds; dp do F1 cai a menos da metade (0,0184 $\rightarrow$ 0,0077).
- Tempo de treino: $\approx$21 s (H0) vs. $\approx$85 s (H1) por simulação ($\approx 4\times$).

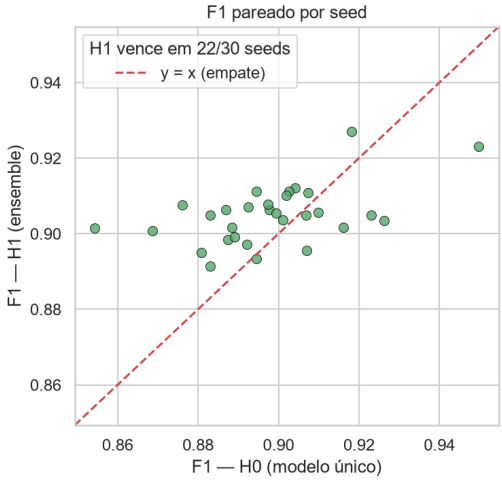
F1 por cenário

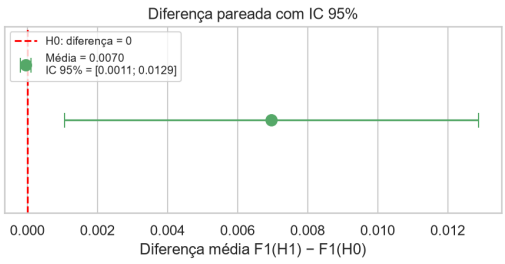


F1 por simulação



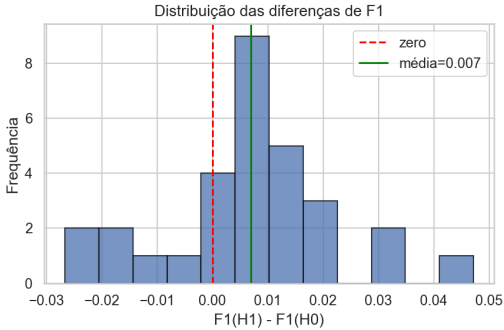
Análise pareada

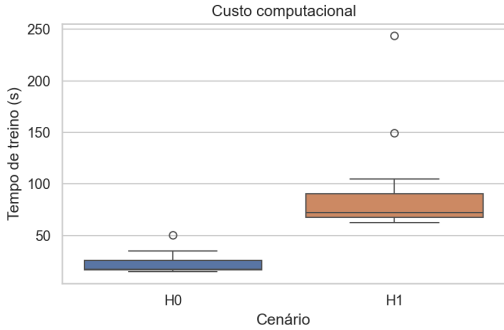




Diferença média 0,0070; IC 95% [0,0011; 0,0129] exclui o zero.

Diferenças e custo computacional

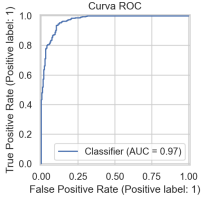


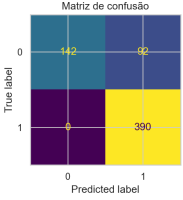


ROC e matriz de confusão (seed 0)

H0

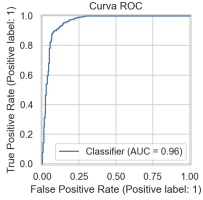
H0 — ROC e matriz (seed 0)

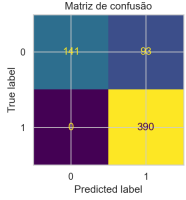




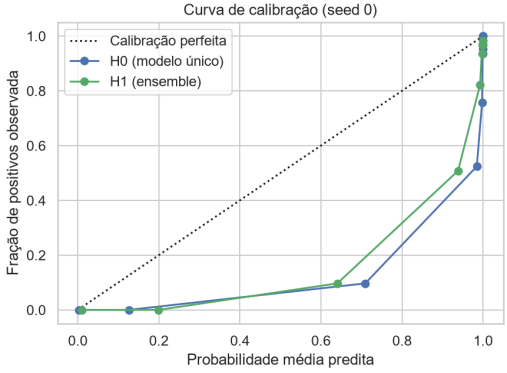
H1

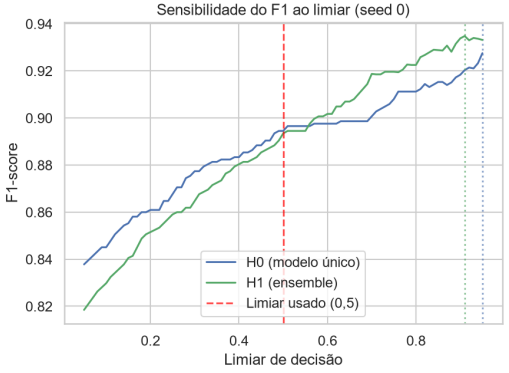
H1 — ROC e matriz (seed 0)





Calibração e limiar de decisão (seed 0)





Zero falsos negativos com limiar 0,5; limiar ótimo $\approx$0,9 elevaria o F1 a $\approx$0,93.

Conclusão estatística

- Rejeita-se H0: o ensemble (H1) é estatisticamente mais eficaz em F1 (alpha=0,05).
- Trade-off: ensemble treina três arquiteturas; tempo de treino tipicamente maior que H0.

Síntese do teste de hipótese

- Shapiro–Wilk: $W = 0{,}9579$, $p = 0{,}2739 \Rightarrow$ diferenças normais $\Rightarrow$ t pareado.
- $t = 2{,}41$, $p = 0{,}011 < \alpha = 0{,}05$ (unilateral) $\Rightarrow$ **rejeita-se H0**.
- Tamanho de efeito: Cohen's $d = 0{,}44$ (pequeno a moderado).
- Recomendação: H1 quando robustez compensa o custo $4\times$; H0 como baseline rápida.

Demonstração

```
python src/simulate.py
python src/finish_pipeline.py
python src/extra_plots.py
```

Obrigado!

Perguntas?