Modelo Único versus Ensemble sob Transfer Learning na Classificação de Pneumonia em Radiografias: um Estudo Comparativo com Inferência Estatística

Enzo de Barros Nunes, Guilherme Cardozo de Castro Melo, Lui Vaz Manso de Queiroz,
Marcelo Bresani Victor de Oliveira, Matheus de Lucena Henriques, Thiago de Lima von Sohsten
Eletiva de Inteligência Artificial — CESAR School
Recife, PE, Brasil
{ebn, gccm, lvmq, mbvo, mlh, tlvs}@cesar.school

***Resumo*—Este trabalho compara duas abordagens de deep learning para classificação binária de pneumonia em radiografias de tórax (dataset PneumoniaMNIST): (i) cenário de hipótese nula (H0), combinando classificação de imagens, transfer learning e um único classificador ResNet18 com fine-tuning a partir de pesos ImageNet; e (ii) cenário de hipótese alternativa (H1), substituindo a terceira técnica por ensemble learning com votação suave entre ResNet18, MobileNetV2 e EfficientNet-B0. Foram realizadas 30 simulações pareadas variando a semente aleatória. A métrica principal é o F1-score, adequada ao desbalanceamento das classes. Testes estatísticos pareados (Shapiro–Wilk seguido de t pareado unilateral) avaliaram se H1 supera H0 com $\alpha = 0{,}05$. O ensemble obteve F1 médio de 0,9050 $\pm$ 0,0077 contra 0,8980 $\pm$ 0,0184 do modelo único, vencendo em 22 das 30 simulações, com $p = 0,011246$ e Cohen's $d = 0,4401$. Rejeita-se H0: o ensemble (H1) é estatisticamente mais eficaz em F1 (alpha=0,05). O ganho vem acompanhado de redução do desvio padrão do F1 a menos da metade, ao custo de aproximadamente quatro vezes o tempo de treinamento.**

***Index Terms*—Visão computacional, transfer learning, ensemble learning, PneumoniaMNIST, teste de hipótese, diagnóstico auxiliado por computador.**

I. Introdução

A pneumonia é uma das principais causas de mortalidade infantil no mundo, e a radiografia de tórax é o exame de imagem mais utilizado para seu diagnóstico. A interpretação dessas imagens, contudo, depende de radiologistas experientes, um recurso escasso em muitas regiões. Nesse contexto, sistemas de diagnóstico auxiliado por computador baseados em deep learning tornaram-se uma linha de pesquisa ativa, com resultados comparáveis aos de especialistas em tarefas específicas [1], [2].

Redes neurais convolucionais (CNNs) alcançam desempenho competitivo nesse domínio quando combinadas com transfer learning a partir de grandes bases de imagens naturais [3], [4]. Ensemble learning, por sua vez, agrega predições de múltiplos modelos e frequentemente reduz a variância do classificador final [5], [6], ao custo de maior tempo de treinamento e inferência. Uma questão prática recorrente é se esse custo adicional se traduz em ganho mensurável e estatisticamente confiável de desempenho — ou se a melhora observada em uma única execução é mero acaso da inicialização aleatória.

Este estudo comparativo combina três técnicas abordadas em sala em dois cenários que diferem apenas na terceira técnica. Fixamos classificação de imagens (técnica A) e transfer learning (técnica B). No cenário de hipótese nula (H0), a técnica C é um classificador único (ResNet18); no cenário de hipótese alternativa (H1), a técnica C alternativa é ensemble learning por votação suave. O objetivo é inferir estatisticamente, por meio de 30 simulações pareadas, qual das duas abordagens é mais eficaz na métrica F1.

As contribuições deste trabalho são: (i) um protocolo experimental pareado e reprodutível com 30 execuções independentes, em que o mesmo modelo base é compartilhado entre os cenários; (ii) inferência estatística formal, com verificação de normalidade, teste pareado unilateral, intervalo de confiança e tamanho de efeito; e (iii) análise do trade-off entre ganho de desempenho e custo computacional, complementada por análises de curvas ROC e precisão-revocação, calibração e sensibilidade ao limiar de decisão.

O restante do artigo está organizado como segue: a Seção II apresenta a fundamentação teórica; a Seção III descreve a metodologia; a Seção IV reporta os resultados; a Seção V discute os achados e limitações; e a Seção VI conclui.

II. Fundamentação Teórica

A. Classificação em visão computacional

Classificação de imagens consiste em aprender uma função que mapeia uma imagem x para um rótulo discreto y. CNNs aprendem hierarquias de características diretamente dos pixels: camadas iniciais detectam bordas e texturas, enquanto camadas profundas capturam padrões semânticos. Utilizamos CNNs com camada final linear seguida de softmax sobre duas classes (normal vs. pneumonia), treinadas com a função de perda de entropia cruzada.

B. Transfer learning

Treinar CNNs profundas do zero requer grandes volumes de dados rotulados, raros no domínio médico. Transfer learning contorna essa limitação: inicializamos os pesos das redes com valores pré-treinados na ImageNet [7], uma base com mais de um milhão de imagens naturais, e realizamos fine-tuning completo no domínio alvo. As características de baixo nível aprendidas em imagens naturais (bordas, gradientes, texturas) transferem-se bem para radiografias, acelerando a convergência e melhorando a generalização quando o conjunto de dados alvo é pequeno [4].

C. Arquiteturas utilizadas

ResNet18 [3] introduz conexões residuais (*skip connections*) que permitem treinar redes profundas mitigando o problema do gradiente evanescente; a variante de 18 camadas oferece bom equilíbrio entre capacidade e custo. **MobileNetV2** [8] emprega convoluções separáveis em profundidade e blocos residuais invertidos com gargalos lineares, visando eficiência computacional. **EfficientNet-B0** [9] é obtida por busca de arquitetura neural e escalonamento composto de profundidade, largura e resolução. A heterogeneidade dessas três famílias arquiteturais é desejável para o ensemble, pois tende a produzir erros menos correlacionados.

D. Ensemble learning

Métodos de comitê combinam múltiplos classificadores para obter decisões mais robustas que as de qualquer membro isolado [5], [10]. No cenário H1, cada modelo i produz probabilidades $p_i(y{=}1 \mid x)$; a votação suave (*soft voting*) define

$$p_{\text{ens}}(y{=}1 \mid x) = \frac{1}{M} \sum_{i=1}^{M} p_i(y{=}1 \mid x), \tag{1}$$

com $M = 3$ modelos. A classe predita usa limiar 0,5. A intuição teórica é que, se os erros dos membros forem parcialmente independentes, a média das probabilidades cancela flutuações individuais, reduzindo a variância do preditor agregado [6].

E. Inferência estatística para comparação de modelos

Comparar duas abordagens por uma única execução é frágil: a inicialização aleatória e o embaralhamento dos dados introduzem variabilidade. O procedimento adequado repete o experimento n vezes e aplica um teste de hipótese sobre as diferenças pareadas. O teste de Shapiro–Wilk [11] verifica a normalidade das diferenças; confirmada a normalidade, o teste t pareado é apropriado; caso contrário, recorre-se ao teste não paramétrico de Wilcoxon [12]. Além do valor-p, reporta-se o tamanho de efeito de Cohen's d [13], que quantifica a magnitude prática da diferença em unidades de desvio padrão.

III. Metodologia

A. Dataset

Utilizamos o PneumoniaMNIST [14], subset do benchmark MedMNIST v2 derivado da base de radiografias pediátricas de Kermany et al. [2], com imagens em escala de cinza na resolução nativa de 28×28 pixels, rotuladas como normal ou pneumonia. A Fig. 1 apresenta exemplos das duas classes: casos de pneumonia tendem a exibir opacidades e consolidações que reduzem o contraste dos campos pulmonares.

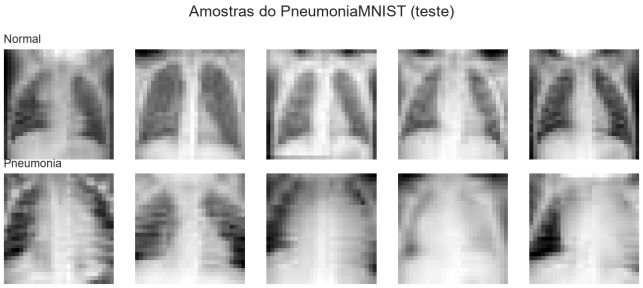


Figura 1. Amostras do conjunto de teste do PneumoniaMNIST: casos normais (acima) e com pneumonia (abaixo).

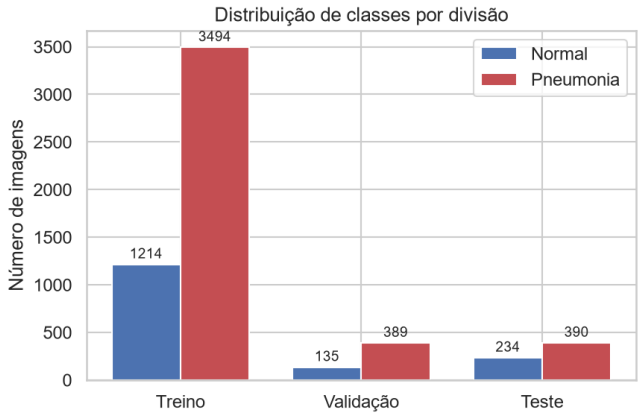


Figura 2. Distribuição de classes nas divisões oficiais do PneumoniaMNIST.

As divisões oficiais de treino (4.708 imagens), validação (524) e teste (624) são mantidas, garantindo comparabilidade com outros trabalhos no benchmark. A Fig. 2 mostra a distribuição de classes por divisão: o conjunto de teste contém 390 casos de pneumonia e 234 normais (cerca de 62% positivos). Esse desbalanceamento motiva a escolha do F1-score como métrica principal, pois a acurácia isolada pode mascarar erros na classe minoritária.

B. Pré-processamento e aumento de dados

As imagens são redimensionadas de 28×28 para 64×64, replicadas em três canais (para compatibilidade com os pesos ImageNet) e normalizadas com as médias e desvios padrão da ImageNet. No treino, aplica-se espelhamento horizontal aleatório como aumento de dados; nas divisões de validação e teste, nenhum aumento é aplicado.

C. Cenários comparados

O protocolo experimental é ilustrado na Fig. 3. **H0 (modelo único):** ResNet18 pré-treinada na ImageNet, com a cabeça de classificação substituída por uma camada binária. **H1 (ensemble):** comitê de ResNet18, MobileNetV2 e EfficientNet-

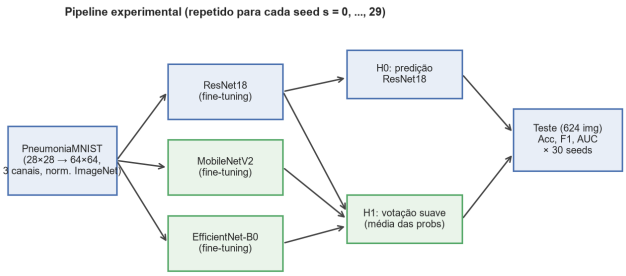


Figura 3. Pipeline experimental. A mesma ResNet18 treinada em cada seed é usada em H0 e como membro do ensemble em H1, garantindo o pareamento.

B0, todos pré-treinados na ImageNet com cabeça binária, combinados por votação suave com pesos uniformes.

D. Protocolo de treinamento

Cada modelo é treinado com o otimizador Adam [15] (taxa de aprendizado 10^{-3}), batch de 128 exemplos e até 5 épocas, com early stopping (paciência de 3 épocas) monitorando a loss de validação. Em cada simulação $s \in \{0, \ldots, 29\}$, a semente aleatória controla a inicialização e o embaralhamento dos dados. Crucialmente, a mesma ResNet18 treinada na simulação s é usada como o modelo de H0 e como membro do ensemble de H1: a diferença entre cenários decorre exclusivamente da adição dos outros dois modelos ao comitê, o que justifica o tratamento pareado das amostras e aumenta o poder estatístico do teste. Os experimentos foram executados em GPU NVIDIA com PyTorch.

E. Métricas e teste de hipótese

Em cada simulação medimos, no conjunto de teste: acurácia, F1-score da classe positiva (métrica principal) e AUC-ROC, além do tempo de treinamento. As hipóteses estatísticas, unilaterais sobre a média do F1, são:

$$H_0 : \mu_{\mathrm{H1}} \leq \mu_{\mathrm{H0}} \quad \text{vs.} \quad H_1 : \mu_{\mathrm{H1}} > \mu_{\mathrm{H0}}, \tag{2}$$

com $\alpha = 0{,}05$. A normalidade das diferenças pareadas $d_s = \mathrm{F1}_{\mathrm{H1},s} - \mathrm{F1}_{\mathrm{H0},s}$ é verificada pelo teste de Shapiro–Wilk; em caso de normalidade aplica-se o teste t pareado unilateral, caso contrário o teste de Wilcoxon pareado. Reportamos ainda o intervalo de confiança de 95% da diferença média e o tamanho de efeito de Cohen's d pareado.

IV. Resultados

A. Desempenho global

A Tabela I resume as métricas dos dois cenários nas 30 simulações, e a Fig. 4 as apresenta graficamente. O ensemble (H1) supera o modelo único (H0) em acurácia e F1 médios e, notavelmente, reduz o desvio padrão do F1 de 0,0184 para 0,0077 — menos da metade — e o da acurácia de 0,0286 para 0,0118, indicando maior estabilidade entre execuções. A AUC média é praticamente equivalente entre os cenários.

Tabela I
Resumo das métricas (média ± desvio padrão, 30 simulações).

Cenário	Acurácia	F1	AUC
H0 (modelo único)	0,8580 ± 0,0286	0,8980 ± 0,0184	0,9691 ± 0,0093
H1 (ensemble)	0,8690 ± 0,0118	0,9050 ± 0,0077	0,9677 ± 0,0074

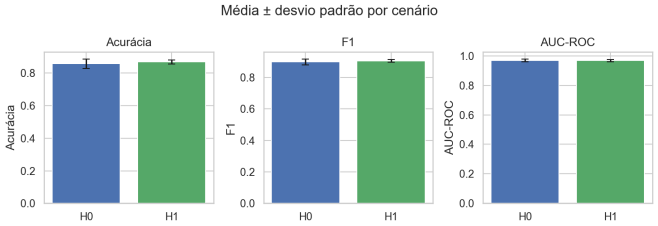


Figura 4. Comparação das métricas médias por cenário (barras de erro: desvio padrão).

As Figs. 5 e 6 mostram as distribuições das métricas: em H1, as caixas são visivelmente mais compactas, confirmando a redução de variância promovida pelo comitê.

B. Análise pareada

A Fig. 7 apresenta o F1 de cada cenário ao longo das 30 seeds, e a Fig. 8 o diagrama de dispersão pareado: cada ponto é uma simulação, e pontos acima da diagonal indicam vitória do ensemble. H1 supera H0 em 22 das 30 seeds. Observa-se ainda que as maiores vitórias do ensemble ocorrem justamente nas seeds em que o modelo único teve desempenho fraco — o comitê "resgata" execuções ruins da ResNet18.

O histograma das diferenças pareadas (Fig. 9) concentra-se em valores positivos, com diferença média de 0,0070. A Fig. 10 visualiza essa diferença com seu intervalo de confiança de 95% (distribuição t, 29 graus de liberdade), $[0{,}0011;\ 0{,}0129]$, que exclui o zero — evidência gráfica consistente com a rejeição da hipótese nula.

C. Teste de hipótese

O teste de Shapiro–Wilk não rejeitou a normalidade das diferenças ($W = 0{,}9579$, $p = 0{,}2739$), habilitando o teste t pareado unilateral, que resultou em $t = 2{,}41$ e $p = 0{,}011246$, com Cohen's $d = 0{,}4401$ (efeito pequeno a moderado). Como $p < \alpha = 0{,}05$: Rejeita-se H0: o ensemble (H1) é estatisticamente mais eficaz em F1 (alpha=0,05).

D. Análise por curvas ROC e precisão-revocação

As Figs. 11 e 12 ilustram curvas ROC e matrizes de confusão representativas (seed 0). Ambos os cenários atingem AUC próxima de 0,96–0,98. As matrizes de confusão revelam um padrão clínico relevante: com o limiar 0,5, os dois cenários obtêm revocação perfeita na classe pneumonia (zero falsos negativos na seed 0), ao custo de cerca de 92 falsos positivos — ou seja, os modelos erram quase exclusivamente ao classificar radiografias normais como pneumonia. Em triagem, esse perfil conservador é preferível ao oposto, mas infla o número de encaminhamentos desnecessários. A Fig. 13 complementa

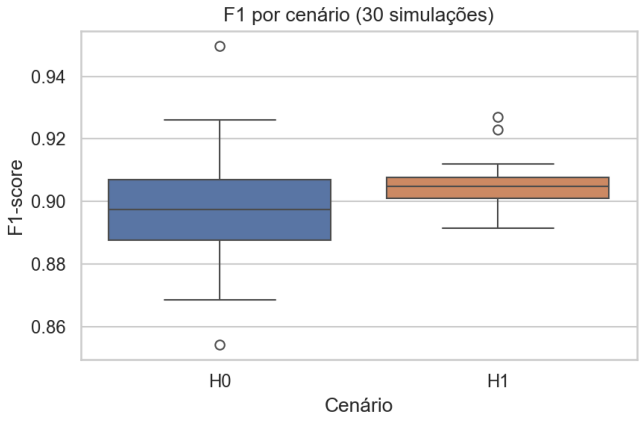


Figura 5. Distribuição do F1-score por cenário nas 30 simulações.

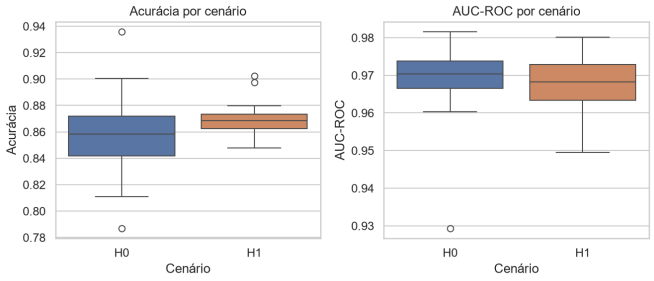


Figura 6. Distribuição da acurácia e da AUC-ROC por cenário.

com as curvas precisão-revocação: a precisão mantém-se alta em quase toda a faixa de revocação.

E. Calibração e sensibilidade ao limiar

A Fig. 14 apresenta as curvas de calibração: ambos os cenários superestimam sistematicamente a probabilidade de pneumonia na região central, fenômeno comum em redes profundas modernas [16]. Coerentemente, a Fig. 15 mostra que o F1 na seed 0 seria maximizado com limiares bem acima de 0,5 (0,91 para o ensemble e ainda mais alto para o modelo único), alcançando cerca de 0,93 contra 0,89 no limiar padrão. Isso sugere que a calibração do limiar na validação é uma melhoria de baixo custo para ambos os cenários — embora, por justiça comparativa, este estudo tenha mantido o limiar fixo em 0,5 para os dois.

F. Custo computacional

As Figs. 16 e 17 quantificam o preço do ensemble: o tempo médio de treinamento sobe de cerca de 21 s (H0) para 85 s (H1) por simulação — razão de aproximadamente $4\times$ —, já que H1 exige treinar as três arquiteturas. A variabilidade do tempo entre seeds (Fig. 17) decorre do early stopping, que encerra o treino em épocas diferentes conforme a evolução da loss de validação. O custo de inferência também triplica, aspecto relevante para implantação em dispositivos com recursos limitados.

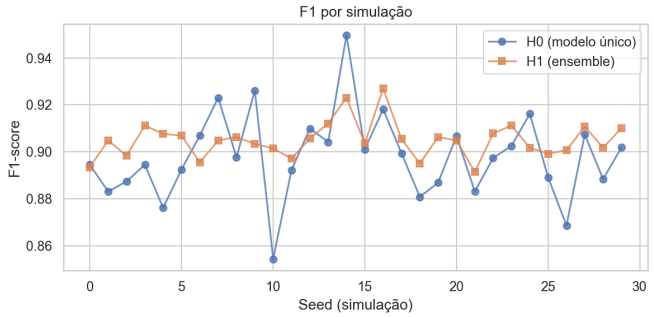


Figura 7. F1 por simulação (seed), evidenciando o pareamento entre cenários.

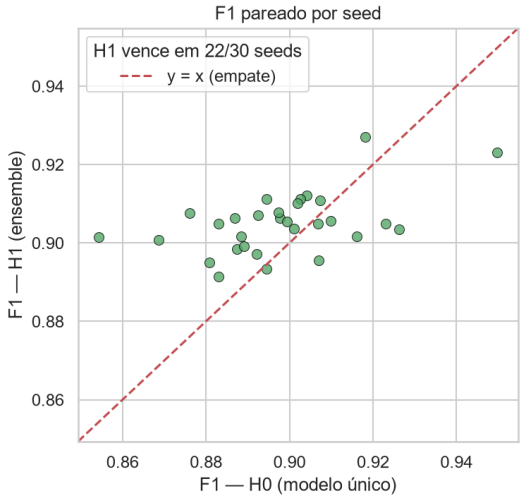


Figura 8. F1 pareado por seed: pontos acima da diagonal indicam vitória do ensemble (22/30).

V. Discussão

O ensemble combina representações complementares de três famílias arquiteturais (blocos residuais, convoluções separáveis invertidas e escalonamento composto) e, neste experimento, obteve F1 médio superior ao modelo único com diferença estatisticamente significativa ($p = 0{,}011$). O efeito é de magnitude pequena a moderada (Cohen's $d = 0{,}44$): o ganho médio de 0,007 em F1 é consistente, mas não drástico.

O benefício mais expressivo talvez seja a redução da variância: os desvios padrão do F1 e da acurácia caem a menos da metade. A análise pareada (Fig. 8) mostra que o comitê atua sobretudo como seguro contra execuções ruins do modelo único — quando a ResNet18 converge mal em uma seed, os outros dois membros compensam. Em aplicações clínicas, essa previsibilidade do desempenho entre re-treinamentos é um atributo desejável, por vezes mais importante que o ganho médio em si.

A análise de erros revelou um perfil assimétrico: com limiar 0,5, ambos os cenários praticamente zeram os falsos negativos ao custo de muitos falsos positivos, refletindo tanto o desbalanceamento do treino (74% de casos positivos) quanto

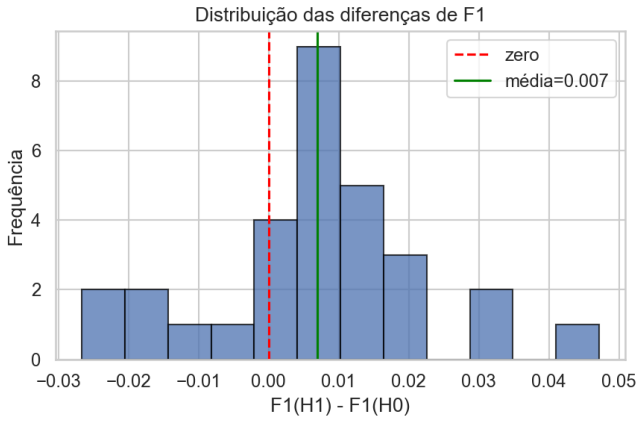


Figura 9. Histograma das diferenças pareadas F1(H1)−F1(H0).

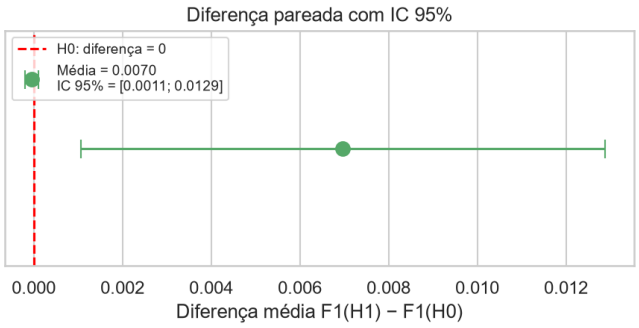


Figura 10. Diferença média pareada do F1 com IC 95%: o intervalo exclui o zero.

a má calibração das probabilidades (Fig. 14). A sensibilidade ao limiar (Fig. 15) indica que uma calibração simples na validação elevaria o F1 de ambos os cenários em cerca de 3–4 pontos percentuais, sem alterar o ranking entre eles.

Quanto ao custo, a razão de $4\times$ no tempo de treino (e $3\times$ na inferência) é o preço direto do comitê. Em cenários com orçamento computacional apertado ou necessidade de inferência em tempo real, o modelo único permanece competitivo, dado que a diferença média de F1 é inferior a um ponto percentual.

Limitações. As imagens de baixa resolução (28×28 nativas, redimensionadas para 64×64) subestimam o desempenho absoluto alcançável com radiografias em resolução plena; o limiar de decisão foi fixado em 0,5 sem calibração; o ensemble usa pesos uniformes, sem ponderação pelos desempenhos individuais dos membros; as análises de ROC, PR, calibração e limiar usam uma única seed representativa; e o teste estatístico cobre apenas a métrica F1, sem correção para múltiplas comparações nas métricas secundárias.

VI. Conclusão

Comparamos modelo único versus ensemble sob transfer learning na classificação de pneumonia (PneumoniaMNIST), com 30 simulações pareadas e inferência estatística formal. Rejeitamos H_0 em favor da hipótese alternativa: o ensemble

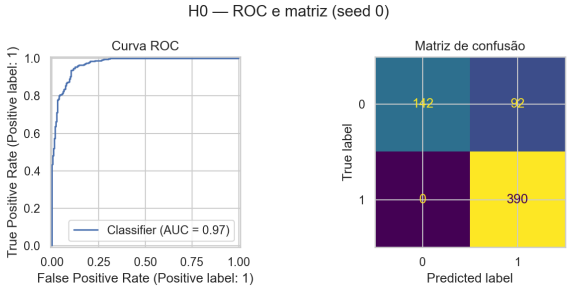


Figura 11. Curva ROC e matriz de confusão do cenário H0 (seed 0).

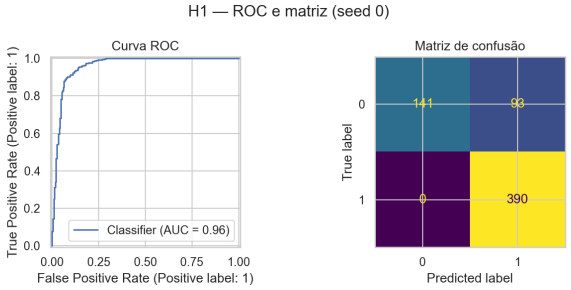


Figura 12. Curva ROC e matriz de confusão do cenário H1 (seed 0).

(H1) é mais eficaz em F1 ($p = 0{,}011 < 0{,}05$), vence em 22 das 30 execuções e é marcadamente mais estável. Para implantação, recomenda-se H1 quando o ganho de robustez compensa o tempo extra de treinamento e inferência; caso contrário, H0 permanece uma baseline forte e aproximadamente quatro vezes mais rápida de treinar.

Trabalhos futuros incluem: calibração do limiar de decisão e das probabilidades (por exemplo, *temperature scaling* [16]); votação ponderada pelo desempenho de validação de cada membro; ensembles maiores e com maior diversidade (variação de dados de treino, como em bagging [10]); validação em radiografias de resolução plena; e extensão do protocolo estatístico a múltiplas métricas com correção de Bonferroni.

Referências

[1] P. Rajpurkar, J. Irvin, K. Zhu *et al.*, "CheXNet: Radiologist-level pneumonia detection on chest x-rays with deep learning," *arXiv preprint arXiv:1711.05225*, 2017.

[2] D. S. Kermany, M. Goldbaum, W. Cai *et al.*, "Identifying medical diagnoses and treatable diseases by image-based deep learning," *Cell*, vol. 172, no. 5, pp. 1122–1131, 2018.

[3] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *CVPR*, 2016, pp. 770–778.

[4] S. J. Pan and Q. Yang, "A survey on transfer learning," *IEEE TKDE*, vol. 22, no. 10, pp. 1345–1359, 2010.

[5] T. G. Dietterich, "Ensemble methods in machine learning," in *International Workshop on Multiple Classifier Systems*. Springer, 2000, pp. 1–15.

[6] M. A. Ganaie, M. Hu, A. K. Malik *et al.*, "Ensemble deep learning: A review," *Engineering Applications of Artificial Intelligence*, vol. 115, p. 105151, 2022.

[7] J. Deng, W. Dong, R. Socher *et al.*, "ImageNet: A large-scale hierarchical image database," in *CVPR*, 2009, pp. 248–255.

[8] M. Sandler, A. Howard, M. Zhu *et al.*, "MobileNetV2: Inverted residuals and linear bottlenecks," in *CVPR*, 2018, pp. 4510–4520.

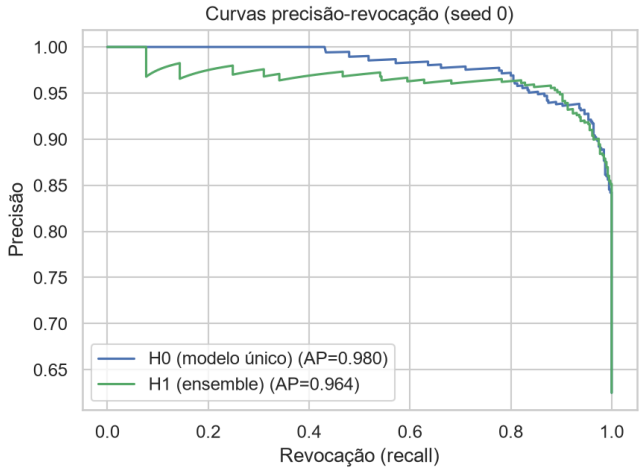


Figura 13. Curvas precisão-revocação dos dois cenários (seed 0), com average precision (AP).

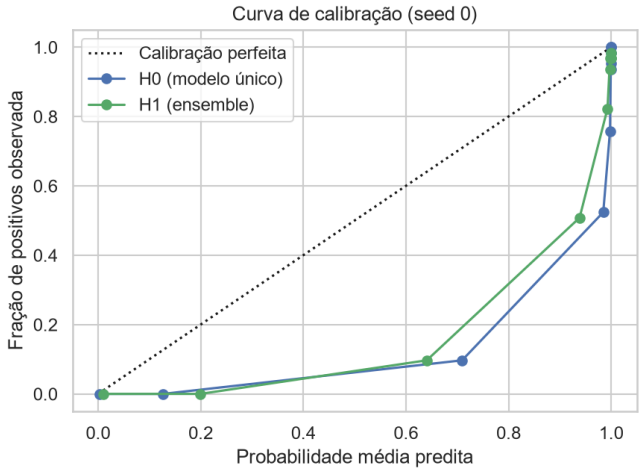


Figura 14. Curvas de calibração (seed 0): pontos abaixo da diagonal indicam superestimação da probabilidade de pneumonia.

[9] M. Tan and Q. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *ICML*, 2019, pp. 6105–6114.

[10] L. Breiman, "Bagging predictors," *Machine Learning*, vol. 24, no. 2, pp. 123–140, 1996.

[11] S. S. Shapiro and M. B. Wilk, "An analysis of variance test for normality (complete samples)," *Biometrika*, vol. 52, no. 3–4, pp. 591–611, 1965.

[12] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.

[13] J. Cohen, *Statistical power analysis for the behavioral sciences*, 2nd ed. Lawrence Erlbaum Associates, 1988.

[14] J. Yang, R. Shi, B. Ni *et al.*, "MedMNIST v2: A large-scale lightweight benchmark for 2D and 3D biomedical image classification," *Scientific Data*, vol. 10, no. 1, p. 41, 2023.

[15] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014.

[16] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *ICML*, 2017, pp. 1321–1330.

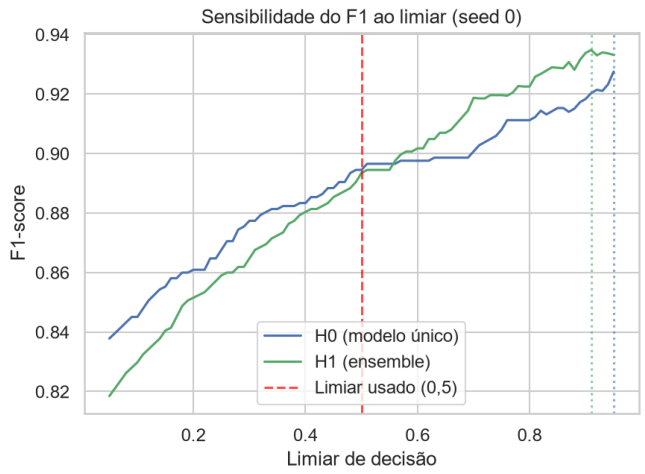


Figura 15. Sensibilidade do F1 ao limiar de decisão (seed 0). As linhas pontilhadas verticais marcam o limiar ótimo de cada cenário.

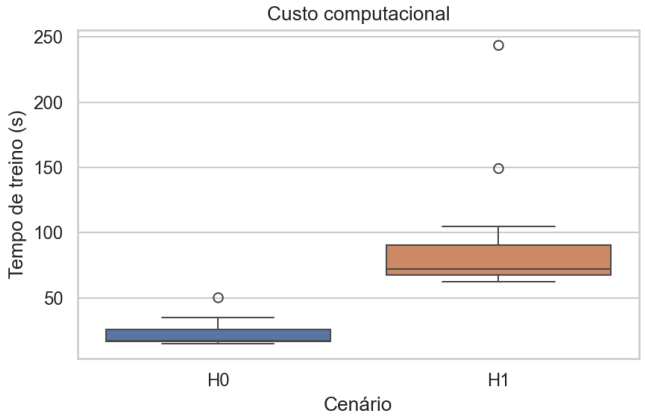


Figura 16. Distribuição do tempo de treinamento por cenário.

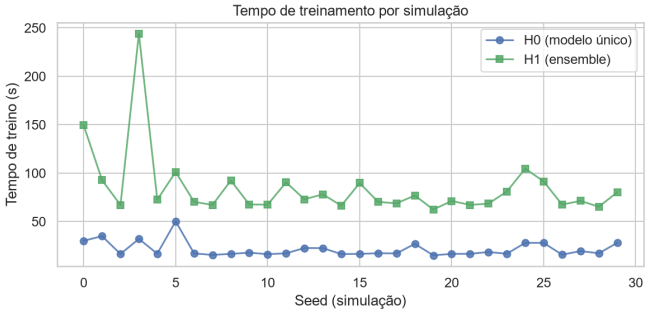


Figura 17. Tempo de treinamento por simulação.